پروژه درس آمار- فاز اول

کوثر خردمند

403100319

پاییز1405

مقدمه

در این فاز از پروژه که دادههای مورد استفاده از پیمایش ملی سلامت و تغذیه دوره ۲۰۲۱ تا ۲۰۲۳ است که توسط مرکز کنترل و پیشگیری بیماریهای آمریکا جمعآوری شده است، هدف برای ما شناخت و آمادهسازی داده، ارائه آمار توصیفی و نهاییسازی سؤال آماری برای بررسی توصیفی شاخص توده بدنی و فشار خون سیستولیک در بزرگسالان ۲۰ سال و بالاتر است. در گزارش فاز اول پروژه ما صرفا دادهها را توصیف میکنیم و ارائه نتایجی به صورت استنباطی نخواهیم داشت.

تحلیلها با زبان Java و کتابخانههای Apache Commons Math (آمار توصیفی) و XChart (نمودارها) انجام شده و تمام کدها در مخزن GitHub پروژه موجود است. خروجی کامل برنامه ممیزی داده در فایل reports/phase1/audit_output.txtذخیره شده است.

منشأ داده و سازوکار جمعآوری

)تسک مشترک(1

دادهها از برنامه NHANES (پیمایش ملی سلامت و تغذیه) گرفته شدهاند که توسط NCHSدر مرکز کنترل و پیشگیری بیماریهای آمریکا (CDC) اجرا میشود. دوره مورد استفاده اوت 2021 تا اوت 2023 است که نخستین انتشار ملی NHANES پس از وقفه دوران همهگیری کرونا است.

NHANESیک پیمایش مقطعی و مشاهدهای است. از هر شرکتکننده ابتدا در خانه مصاحبه انجام میشود و سپس او در یک مرکز معاینه سیار (MEC) معاینههای بدنی از جمله اندازهگیریهای بدنی و فشارخون را انجام میدهد. فایل DEMO_L حاصل مصاحبه و فایلهای BMX_L و BPXO_L حاصل معاینه هستند. در این مطالعه هیچ مداخله یا تخصیص تصادفی وجود ندارد، پس نه آزمایش تصادفی بلکه مطالعه مشاهدهای است.

فایلها عمومی هستند و محدودیت دسترسی ندارند. در اکتبر 2026 از وبسایت رسمی CDC با قالب XPT دریافت و با یک ابزار تبدیل به CSV تبدیل شدند. این ابزار یک ستون شماره ردیف اضافه میکند که در کد LoadData.java مدیریت شده است. مراحل کامل بازسازی داده در data/README.md آمده است.

واحد مشاهده و ساختار داده

)تسک مشترک(2

هر سطر در هر یک از سه فایل نماینده یک شرکتکننده است که با متغیر SEQN شناسایی میشود. در هیچ فایلی SEQN تکراری وجود نداشت، پس هر فرد دقیقا یک سطر در هر فایل دارد و ساختار تکرارشونده یا سلسلهمراتبی (مثلا چند مراجعه برای یک نفر) در داده وجود ندارد.

فایلها تودرتو هستند: همه افراد BPXO_L در BMX_L و DEMO_L هم حضور دارند و همه افراد BMX_L در DEMO_L هستند، چون هر شرکتکننده مصاحبهشده لزوما معاینه نمیشود. جدول زیر این ساختار را نشان میدهد.

فایل	بخش	تعداد سطر	رابطه با فایلهای دیگر
DEMO_L	مصاحبه	11933	شامل همه شرکتکنندگان
BMX_L	معاینه	8860	زیرمجموعهDEMO_L
BPXO_L	معاینه	7801	زیرمجموعه BMX_L و DEMO_L

منبع داده ها و ادغام

)الزام الف(

ما از سه فایل زیر تحت عنوان داده استفاده کردیم:

DEMO_L:اطلاعات جمعیت شناختی

BMX_L:اندازه گیری های بدنی

BPXO_L:اندازه گیری فشار خون

برای اینکه رکوردهای یک نفر را از سه فایل کنار هم بیاوریم و رکوردی کامل بسازیم از متغیر SEQN استفاده کردیم. وچون صرفا به اطلاعات افرادی نیاز داشتیم که در هر سه فایل باشند نوع ادغام از نوع inner join است.

تعداد رکوردهای اولیه برای DEMO, BMX, BPXO به ترتیب 8860 ،11933 و 7801بود که پس از ادغام به تعداد 7801 رسید زیرا در واقع به تعداد کوچکترین رکورد مشترک داریم. در هیچکدام از سه فایل SEQN تکراری وجود نداشت و هر فرد موجود در BMX_L و BPXO_L در DEMO_L نیز حضور داشت.

فایل	تعداد رکورد	افراد یکتا(SEQN)
DEMO_L	11933	11933
BMX_L	8860	8860
BPXO_L	7801	7801
مشترک بین هر سه فایل	7801	7801

نمونهگیری، انتخاب و قابلیت تعمیم

)تسک مشترک(3

NHANESاز نمونهگیری احتمالی چندمرحلهای استفاده میکند: ابتدا واحدهای اولیه نمونهگیری (PSU) در طبقههای جغرافیایی انتخاب میشوند، سپس خانوارها و در نهایت افراد. برخی گروههای جمعیتی عمدا بیشنمونهگیری میشوند تا برای هر گروه داده کافی برای تحلیل وجود داشته باشد. بنابراین نمونه ما یک نمونه ساده تصادفی نیست و احتمال انتخاب افراد برابر نیست.

قابلیت تعمیم: با استفاده از وزن WTMEC2YR میتوان نتایج را به جمعیت غیرنهادی ساکن آمریکا (بزرگسالان 20 سال و بالاتر) در دوره اوت 2021 تا اوت 2023 تعمیم داد. بدون وزن، نتایج فقط درباره افراد موجود در نمونه معتبرند. افراد نهادی مانند زندانیان و نظامیان در جامعه هدف نیستند. همچنین چون مطالعه مشاهدهای است، از آن نمیتوان رابطه علّی نتیجه گرفت. افرادی هم که معاینه نشدهاند یا فشارخونشان ثبت نشده از تحلیل ما کنار رفتهاند که در بخشهای بعد بررسی شده است.

نقش وزنهای نمونهگیری

)الزام الف(2

در واقع همانطور که در درس هم گفته شد هدف این است که ما با انتخاب یک جامعه آماری مناسب نتایجمان را تا حد ممکن به کل جامعه تعمیم دهیم. به دلیل جمعیت بالای آمریکا و پراکندگی زیاد آن روشی که برای نمونهگیری استفاده شده است نمونهگیری چندمرحلهای است اما نکتهای که وجود دارد این است که NHANESبا احتمال بیشتری اقلیتها را در نظر میگیرد یعنی سهم آنها از سهم واقعی آنها در جامعه بیشتر است و دلیل این کار این است که میخواهد داده کافی برای تحلیل سلامتشان داشته باشد و این یعنی هر فرد نماینده تعداد متفاوتی از افراد جامعه است. و از سوی دیگر بعضی از افرادی که انتخاب شدهاند همکاری نمیکنند و راهحلی که برای این موضوع استفاده شده است این است که به افراد دیگری که همکاری کردهاند وزن بیشتری تعلق گیرد تا جای خالی آنان پر شود. پس در نتیجه هر فرد با احتمال برابر انتخاب نمیشود و برای اینکه برآوردهای ما از میانگین سوگیری خاصی نداشته باشد از وزن مخصوص بخش معاینه WTMEC2YRاستفاده کردیم تا وزنها را اعمال کنیم. (وزن دیگر WTINT2YR ، است که وزن مخصوص پرسشنامه است نه معاینه(

علاوه بر وزن، طرح نمونهگیری شامل متغیرهای طبقه (SDMVSTRA) و خوشه (SDMVPSU)هم هست. در این فاز فقط از وزن استفاده میکنیم و این دو متغیر برای محاسبه خطای استاندارد در فازهای بعد اهمیت پیدا میکنند.

طبقهبندی متغیرها

)تسک مشترک(4

متغیر	کد	نوع	مقیاس و نقش
شاخص توده بدنی	BMXBMI	کمی پیوسته	نسبتی؛ پاسخ اصلی
فشارخون سیستولیک (قرائت اول)	BPXOSY1	کمی پیوسته	نسبتی؛ متغیر کمکی
سن	RIDAGEYR	کمی گسسته	نسبتی؛ کدگذاری سقفی در 80
گروه سنی (ساختهشده)	—	ترتیبی	گروهبندی: 20-39، 40-59، 60+
جنس	RIAGENDR	اسمی دودویی	گروهبندی (1 = مرد، 2 = زن)
وزن معاینه	WTMEC2YR	کمی پیوسته	وزن طرح نمونهگیری
طبقه و خوشه طرح	SDMVSTRA، SDMVPSU	اسمی	متغیرهای طرح نمونهگیری
شناسه	SEQN	شناسه	کلید ادغام

این طبقهبندی انتخاب خلاصههای آماری را تعیین میکند: برای متغیرهای اسمی و ترتیبی (جنس، گروه سنی) جدول فراوانی و درصد، و برای متغیرهای کمی میانگین، میانه، انحراف معیار و چارکها گزارش میشود.

تعریف جمعیت تحلیلی

)الزام الف(4

در این بخش جمعیت تحلیلی را گامبهگام تعریف میکنیم. معیارهای ورود به تحلیل اینها هستند: سن 20 سال و بالاتر، و وجود همزمان ،BMI فشارخون سیستولیک (BPXOSY1)و وزن معاینه .(WTMEC2YR) حذف افراد زیر 20 سال مشکلی برای تفسیر ایجاد نمیکند، چون جمعیت مورد نظر ما بزرگسالان هستند. جدول زیر تعداد افراد باقیمانده و حذفشده را بعد از هر مرحله نشان میدهد.

مرحله	معیار	باقیمانده	حذفشده
0	همه شرکتکنندگانDEMO_L	11933	—
1	سن 20 سال و بالاتر	7809	4124
2	BMIموجود	5970	1839
3	فشارخون سیستولیک موجود	5805	165
4	وزن معاینه موجود و مثبت	5805	0

از 1839 نفر حذفشده در مرحله ،2 تعداد 1745 نفر در BMX_L حضور ندارند و 94نفر رکورد دارند ولی BMI برایشان ثبت نشده است. تعداد بزرگسالان غایب در BPXO_L هم 1745 نفر است که به احتمال زیاد همان افرادی هستند که در بخش معاینه شرکت نکردهاند (این موضوع با متغیر RIDSTATR بررسی نشده است). در مرحله ،3 هر 165 نفر حذفشده در BPXO_L حضور دارند ولی فشارخون سیستولیک آنها ثبت نشده است. در مرحله 4 کسی حذف نشد چون همه افراد باقیمانده وزن معاینه مثبت دارند. نمونه نهایی 5805 نفر است.

برای فشارخون فقط قرائت اول (BPXOSY1) را استفاده کردیم، هرچند فایل BPXO_Lدو قرائت دیگر BPXOSY2) و (BPXOSY3 هم دارد. این انتخاب برای

ساده نگه داشتن توصیف در این فاز است و در فازهای بعد میتوان میانگین قرائتها را بهعنوان تحلیل جایگزین بررسی کرد.

ممیزی کیفیت داده

)تسک مشترک(5

پیش از تحلیل، کیفیت داده را با برنامه Audit.java بررسی کردیم. نتیجه هر بررسی و تصمیم ما در جدول زیر آمده است.

بررسی	نتیجه	تصمیم و دلیل
SEQNتکراری	0در هر سه فایل	نیاز به اقدام نیست
سلول متنی غیرعددی در ستونهای اصلی	0	نیاز به اقدام نیست
سن، جنس و وزن گمشده (بزرگسالان)	0	نیاز به اقدام نیست
BMIگمشده	1839نفر (23.55% بزرگسالان(	حذف (تحلیل موارد کامل)؛ جایگذاری با مقدار دلخواه سوگیری ایجاد میکند
فشارخون سیستولیک گمشده	1946نفر (24.92% بزرگسالان(	حذف، به همین دلیل
BMIخارج از بازه 10 تا80	0	اقدامی لازم نیست (دامنه مشاهدهشده 11.1 تا(68.9
فشارخون خارج از بازه 60 تا 260	0	اقدامی لازم نیست (دامنه مشاهدهشده 75 تا(225
وزن غیرمثبت، جنس غیر از 1 و ،2 کد ویژه 777 یا بیشتر	0	اقدامی لازم نیست
سن ثبتشده) «80» کدگذاری سقفی(	308نفر(5.31%)	نگه داشته شد؛ در تفسیر، تفاوت سنین بالای 80 قابل تشخیص نیست

بازههای 10 تا 80 برای BMI و 60 تا 260 برای فشارخون مقادیر محتملی هستند که خودمان برای ممیزی تعریف کردیم و حدود رسمی NHANES نیستند.

رکورد تکراری و ناسازگاری منطقی (مانند وزن یا سن غیرممکن) در داده یافت نشد.

بررسی سوگیری ناشی از حذف افراد فاقد فشارخون

)الزام الف(4

در مرحله 165 ،3 بزرگسال که BMI و وزن معاینه دارند فقط به این دلیل حذف شدند که فشارخون سیستولیک نداشتند. جدول زیر این گروه را با نمونه اصلی مقایسه میکند.

ویژگی	نمونه اصلی	حذفشدگان (فاقد فشارخون)
تعداد	5805	165
میانگین سن	53.9	51.8
میانه سن	57	51
درصد زنان	54.9	63.0
درصد 60 ساله و بالاتر	45.7	40.6
میانگینBMI	29.73	33.24
میانهBMI	28.40	29.60

گروه حذفشده حدود 2.8 درصد از 5970 بزرگسال دارای BMI است. میانگین BMIدر آنها حدود 3.5 واحد بیشتر است، اما اختلاف میانه فقط 1.2 است؛ یعنی بخشی از اختلاف میانگین از چند مقدار بسیار بزرگ میآید. با 165 نفر این مقایسه فقط توصیفی است. اینکه چرا فشارخون این افراد ثبت نشده در داده بررسی نشده و هر توضیحی فقط یک فرضیه است. وزنهای نمونهگیری این حذف را جبران نمیکنند. اثر آن در فاز پنجم با تحلیل حساسیت (تکرار تحلیل روی نمونهای که فقط BMIرا لازم دارد) بررسی خواهد شد.

آمار توصیفی

)تسکهای مشترک 6 و (7

)این بخش را در Analysis.java و Audit.java با استفاده از کتابخانه DescriptiveStatisticsمحاسبه کردیم(

آمار توصیفی شاخص توده بدنیBMI

شاخص	مقدار(kg/m^2)
میانگین	29.73
میانه	28.40
انحراف معیار	7.15
چارک اولQ1	24.70
چارک سومQ3	33.50
دامنه بین چارکیIQR	8.80
حداقل	11.10
حداکثر	68.90

میانگین BMI برابر 29.73 است که کمی کمتر از آستانه 30 (چاقی برای یک فرد، طبق استانداردهای سازمان جهانی بهداشت) است. میانگین از میانه (28.40) بزرگتر است، یعنی توزیع راستچوله است که در نمودار جلوتر هم دیده میشود: تعداد کمی از افراد چاقی شدید دارند و میانگین را بالا میکشند، در حالی که میانه به این مقادیر شدید حساس نیست.

به همین دلیل برای BMI میانه و دامنه بین چارکی (8.80) خلاصههای مقاومتری هستند. میانگین و انحراف معیار (7.15) را هم گزارش میکنیم چون در فازهای

بعد مقایسه میانگینها هدف اصلی ماست، ولی باید به یاد داشت که مقادیر شدید روی آنها اثر میگذارند.

آمار توصیفی فشار خون سیستولیک

شاخص	مقدارmmHg
میانگین	123.02
میانه	121.00
انحراف معیار	18.47
چارک اولQ1	110.00
چارک سومQ3	133.00
دامنه بین چارکیIQR	23.00
حداقل	75.00
حداکثر	225.00

میانگین 123.02 میلیمتر جیوه کمی بزرگتر از میانه 121.00 است، پس توزیع فشارخون تقریبا متقارن با چولگی ملایم به راست است. به همین دلیل هم میانگین و انحراف معیار و هم میانه و دامنه بین چارکی (23.00) برای آن مناسباند. انجمن قلب آمریکا فشار سیستولیک 120 تا 129 را «ارتفاعیافته (elevated) «میداند و میانگین نمونه ما در همین بازه است؛ البته این دستهبندی برای افراد تعریف شده و برای میانگین جمعیت فقط یک مرجع تقریبی است.

انحراف معیار (18.47) عدد کوچکی نیست و یعنی پراکندگی قابل توجهی داریم. مقادیر حداقل و حداکثر 75) و (225 هم در فاصله نسبتا زیادی از هم قرار دارند که نشاندهنده بازه واقعی فشارخون در بزرگسالان است.

آمار توصیفی سن

شاخص	مقدار (سال)
میانگین	53.85
میانه	57.00
انحراف معیار	17.09
چارک اولQ1	39.00
چارک سومQ3	68.00
دامنه بین چارکیIQR	29.00
حداقل	20.00
حداکثر	80.00

میانگین سن (53.85) کمتر از میانه (57) است، یعنی توزیع کمی به چپ کشیده است و نمونه نسبتا مسن است 45.74%) افراد 60 ساله یا بالاتر). حداکثر 80 بهدلیل کدگذاری سقفی است و 308 نفر (5.31%) این مقدار را دارند. برای سن میانه و دامنه بین چارکی مناسبترند.

جدولهای فراوانی

جدول فراوانی جنس

جنس	تعداد	درصد فراوانی
مرد	2619	%45.12
زن	3186	%54.88
مجموع	5805	%100

جدول فراوانی گروه سنی

گروه سنی	تعداد	درصد فراوانی
20-39	1482	%25.53
40-59	1668	%28.73
60+	2655	%45.74
مجموع	5805	%100

زنان کمی بیشتر از مردان هستند (54.88%) در برابر (45.12% و گروه 60 ساله و بالاتر بزرگترین گروه سنی است. هر پنج گروه (دو جنس و سه گروه سنی) تعداد زیادی مشاهده دارند که برای مقایسههای بعدی مناسب است.

مقایسه توصیفی BMI بین گروهها

)تسک مشترک(9

گروه	تعداد	میانگین خام	میانه	انحراف معیار	میانگین وزندار
همه	5805	29.73	28.40	7.15	29.60
مرد	2619	29.25	28.10	6.34	29.35
زن	3186	30.13	28.70	7.73	29.84
سن20-39	1482	29.34	27.60	7.81	28.99
سن40-59	1668	30.48	29.00	7.59	30.54
سن60+	2655	29.48	28.50	6.40	29.28

این مقایسه صرفا توصیفی است و هنوز ادعای استنباطی نداریم. زنان میانگین 30.13)در برابر (29.25 و میانه 28.70) در برابر (28.10 کمی بیشتری دارند و پراکندگی BMI در آنها بیشتر است (انحراف معیار 7.73 در برابر .(6.34 برحسب سن، الگو یکنواخت نیست: بیشترین میانگین در گروه 40-59 سال (30.48)است و کمترین در گروه 20-39 سال ،(29.34) اما میانگین گروه 60 سال و بالاتر (29.48) تقریبا برابر گروه جوانتر است. انحراف معیار گروه +60 کمتر است (6.40) که با کوتاهتر بودن دنباله چاقی شدید در این سنین سازگار است.

با اعمال وزن، میانگین گروهها حداکثر حدود 0.35 واحد تغییر میکند و اختلاف میانگین زنان و مردان از 0.88 به 0.49 کاهش مییابد. اینکه این تفاوتها فراتر از تغییرات تصادفی نمونه هستند یا نه، در فاز سوم بررسی میشود.

مقایسه برآورد خام و وزندار

)الزام الف(3

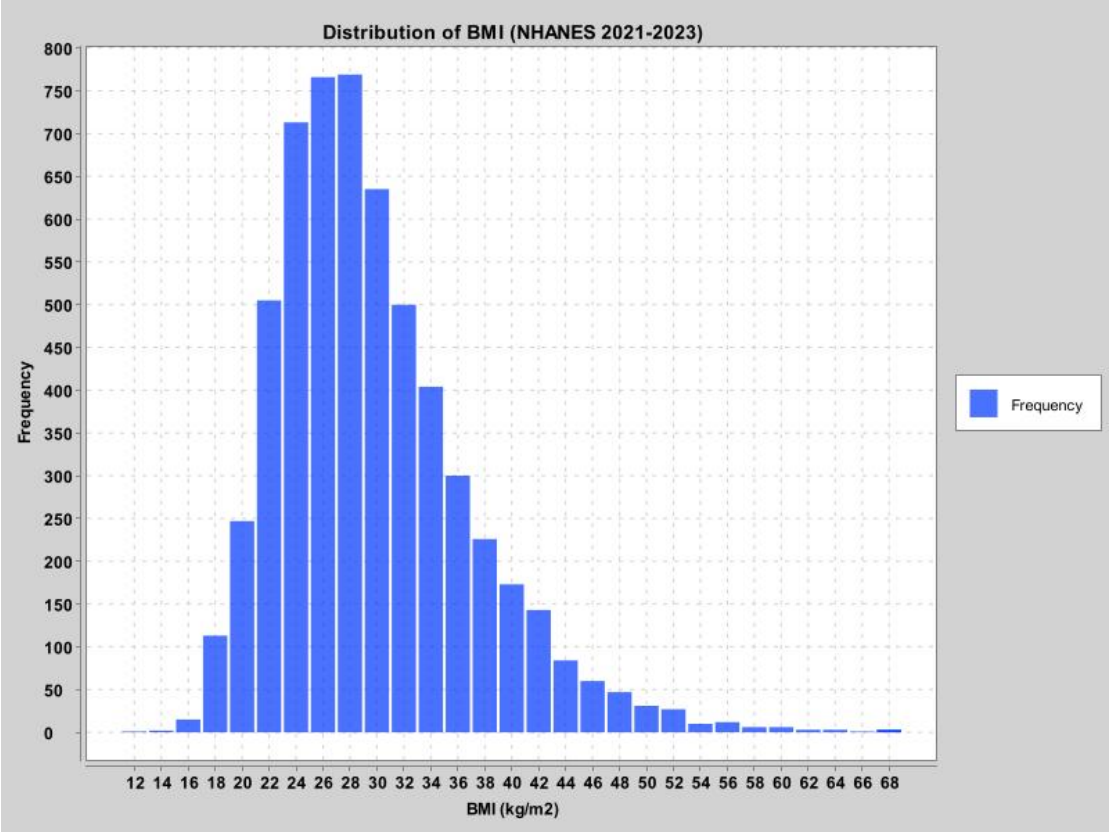
شاخص	برآورد خام	برآورد وزندار	تفاوت
میانگینBMI	29.73	29.60	0.13
میانگین فشارخون	123.02	121.22	1.80
شیوع چاقی(BMI ≥ 30)	%40.91	%40.12	%0.79

تفاوت دو برآورد برای میانگین BMI فقط 0.13 و برای شیوع چاقی 0.79 درصد است، یعنی در این داده وزندهی روی این دو برآورد اثر کمی دارد. این نتیجه بهتنهایی ثابت نمیکند که نمونه خام نماینده جمعیت است، چون ممکن است وزنها اثرهای متفاوتی روی زیرگروهها داشته باشند که در میانگین کل خنثی میشوند.

برای فشارخون تفاوت بیشتر است: برآورد وزندار 1.80 میلیمتر جیوه کمتر از برآورد خام است. در این فاز علت آن را بررسی نکردهایم. چند توضیح ممکن این است که ترکیب سنی، جنسی یا قومی نمونه خام با جمعیت متفاوت است (مثلا به دلیل بیشنمونهگیری برخی گروهها) یا اینکه وزنها بیپاسخی را تعدیل میکنند. نمونه ما نسبتا مسن است (میانگین سن (53.9 که میتواند با فشارخون بالاتر مرتبط باشد، اما این فقط یک فرضیه است؛ برای بررسی آن باید میانگین سن وزندار و توزیع گروههای قومی هم محاسبه شود.

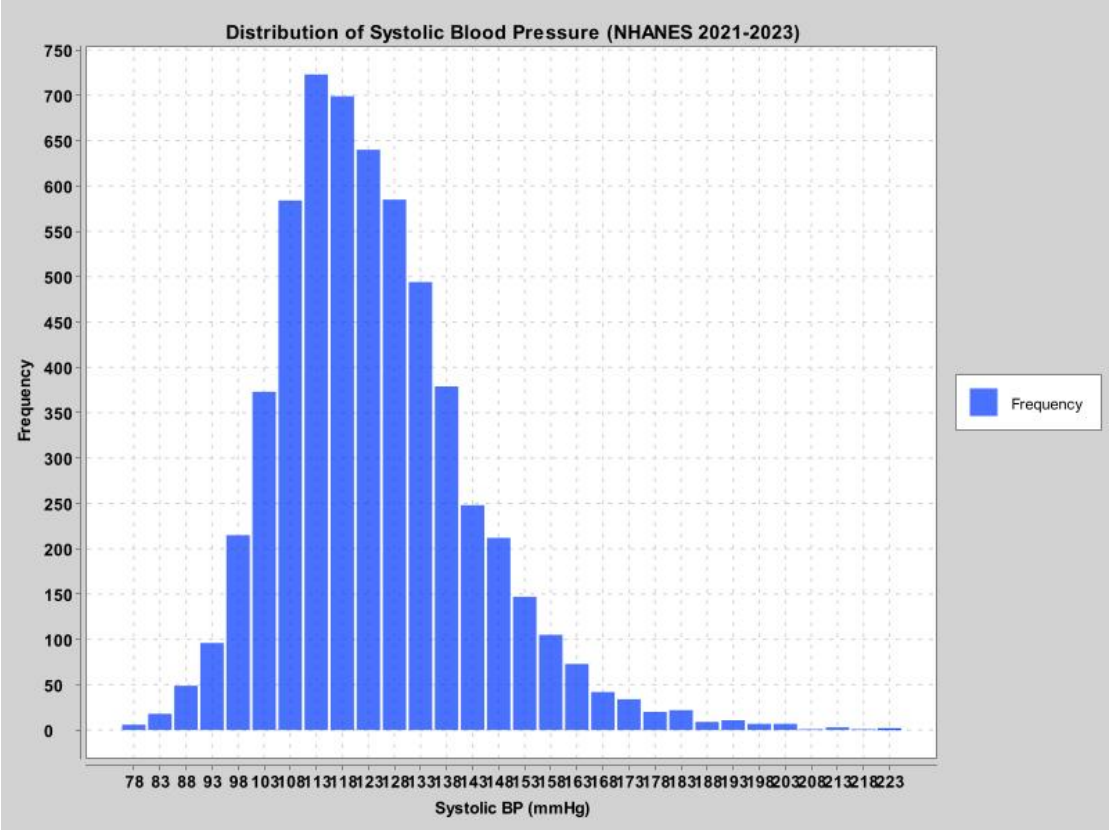
نمودارها

همه نمودارها روی نمونه نهایی (n = 5805) و بدون وزن رسم شده‌اند.



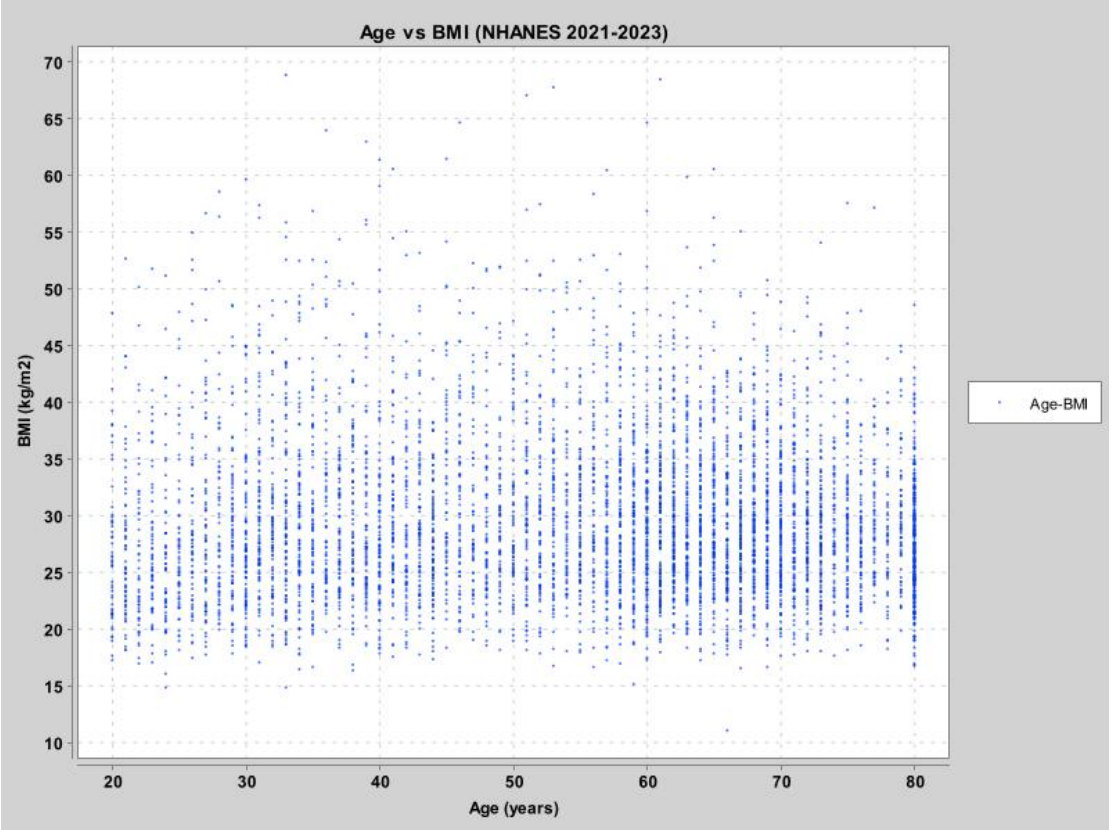
هیستوگرامBMI

این نمودار توزیع شاخص توده بدنی را نشان میدهد. بیشترین فراوانی در حدود BMIبین 22 تا 30 است، اما دنباله توزیع به سمت مقادیر بزرگتر تا 68 نیز کشیده شده است؛ یعنی تعداد کمی از افراد میانگین را بالا میکشند و میانگین بزرگتر از میانه است. همینطور که مشاهده میشود توزیع راستچوله است و نرمال نیست.



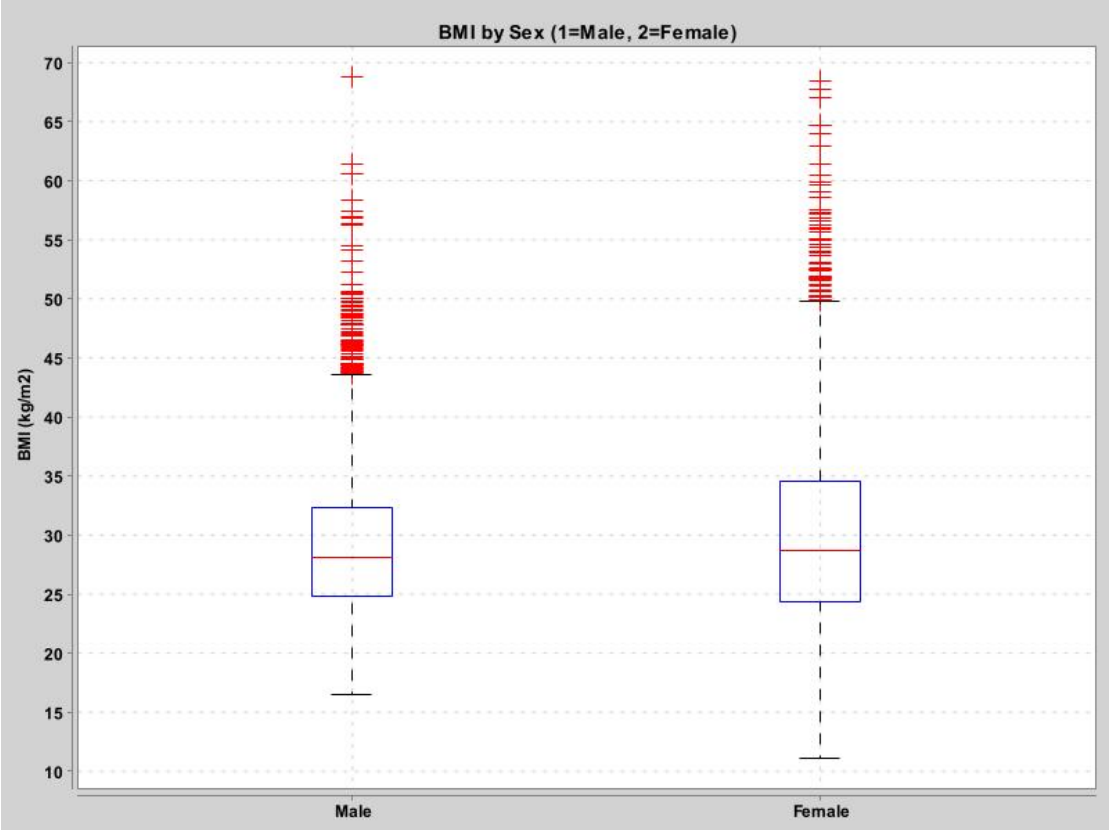
هیستوگرام فشارخون سیستولیک

این نمودار نسبت به قبلی به نرمال بودن نزدیکتر است اما باز هم کمی راستچوله است، به دلیل افرادی که فشارخون بالا دارند، و از حدود 138 به بعد فراوانیها کاهشی است. یک توضیح ممکن (فقط یک فرضیه، نه نتیجه داده) این است که فشارخون تحت تاثیر عوامل فیزیولوژیکی زیادی است که هرکدام اثر کوچکی دارند و طبق شهود قضیه حد مرکزی مجموع چنین اثرهایی به توزیعی نزدیک به نرمال میانجامد، در حالی که BMI بیشتر به سبک زندگی وابسته است.



رابطه بین سن و شاخص توده بدنی

در این نمودار هر نقطه نماینده BMI یک فرد با سن مشخص است. رابطه خطی واضحی دیده نمیشود. از سن 20 تا حدود 50 تعداد افراد با BMI خیلی بالا بیشتر از بازه 50 به بعد است، یعنی پراکندگی مقادیر بسیار بالا با سن کاهش مییابد. از روی نمودار نمیتوان علت را فهمید؛ یک فرضیه ممکن این است که افراد با چاقی شدید در سنین بالا کمتر زنده میمانند یا کمتر در نمونه حضور دارند، اما چون داده مقطعی است این فرضیه با این داده قابل آزمون نیست. ستون عمودی نقاط در سن 80به دلیل کدگذاری سقفی سن است 308) نفر) و چون نقاط زیادی روی هم افتادهاند، تراکم واقعی نقاط از روی نمودار بهخوبی خوانده نمیشود.



مقایسه توزیع BMI بین مردان و زنان

خط وسط هر جعبه میانه است که تقریبا برای هردو جنس برابر با 28 است. برای مردان بالای حدود 43 و برای زنان بالای حدود 50 هر مقدار پرت محسوب میشود. وجود تعداد زیاد پرت در بالا و بلندتر بودن سبیل بالایی نسبت به پایینی نشان میدهد توزیع BMI در هر دو گروه راستچوله است. همچنین جعبه زنان بلندتر است (حدود 24 تا 35 در مقابل 25 تا 32 برای مردان)، یعنی پراکندگی BMIدر زنان بیشتر است. چون میانه در هردو تقریبا یکسان است نمیتوان صرفا از روی این نمودار تعیین کرد که زنان چاقترند یا مردان. فقط میتوان گفت چون خط 30 داخل جعبه هر دو قرار دارد و Q3 زنان بالاتر است، ممکن است سهم زنان با BMI بالای 30 بیشتر باشد.

سؤال آماری

)تسک مشترک(10

»آیا میانگین BMI در بزرگسالان 20 سال و بالاتر ساکن آمریکا (اوت 2021 تا اوت (2023 میان سه گروه سنی 59-40 ،39-20) و 60 سال و بالاتر) و میان دو جنس متفاوت است، و آیا تصویر حاصل با در نظر گرفتن وزنهای نمونهگیری معاینه NHANES تغییر میکند؟«

چرا این سؤال برای دادههای ما مناسب است؟

در سؤال مطرح شده متغیرهای ،BMI سن و جنس وجود دارند و همچنین به وزن نمونه هم اشاره شده و دادههای NHANES نیز دقیقا این متغیرها را دارد. دلیل بعدی هم تعداد کافی دادهها است: هر یک از پنج گروه (دو جنس و سه گروه سنی) بین 1482 تا 3186 نفر دارد که برای برآورد دقیق میانگین گروهها کافی است. همچنین نمودارها و جدول مقایسه نشان دادند که پراکندگی BMI در مردان و زنان تفاوت دارد، میانگین BMI در گروههای سنی یکنواخت نیست و در سنین بالای 60سال دنباله چاقی شدید کوتاهتر میشود. این شواهد توصیفی، سؤال ما را با داده هماهنگ میکند. این سؤال از نوع توصیفی و مقایسهای است و پاسخ استنباطی آن در فاز سوم داده خواهد شد.

محدودیتها

اولین محدودیت ما مشاهدهای بودن دادهها است یعنی ما صرفا میتوانیم همبستگی را نشان دهیم و نه علیت را؛ در واقع مانند همان مثال مطرح شده در کارگاه که مصرف شیر و دریافت جایزه نوبل در حالی که عامل سوم رفاه است که نادیده گرفته میشود. اینجا هم نمیتوانیم بگوییم اگر افراد چاق فشارخون بالا دارند پس چاقی عامل فشارخون بالاست (مثل تغذیه نامناسب است که باعث هردو اینها میشود).

دومین محدودیت ما دادههای گمشده است. از بزرگسالان 1745 ،نفر در BMX_L حضور نداشتند 94 ،نفر BMI ثبتشده نداشتند و 165 نفر فشارخون سیستولیک ثبتشده نداشتند و حذف شدند. گمشدگی ناشی از شرکت نکردن در معاینه تا حدی با وزن WTMEC2YR تعدیل میشود، اما حذف 165 نفر فاقد فشارخون را وزنها جبران نمیکنند و چون میانگین BMI این گروه حدود 3.5 واحد بالاتر است (جدول بخش قبل) ممکن است سوگیری ایجاد کند. اثر این حذف در فاز پنجم با تحلیل حساسیت بررسی میشود.

سومین محدودیت ما این است که دادهها برای یک مقطع زمانی دو ساله هستند یعنی نمیتوانیم تغییرات در طول زمان را ببینیم بخصوص اینکه بنظرم چون بازه زمانی با شیوع کرونا همپوشانی دارد و آن بازه زمانی شرایط خاص محسوب میشود شاید داشتن داده در بازههای زمانی دیگر نیز به دقیق کردن برآورد کمک میکرد. البته اینکه حتی مجموعه افرادی که آزمایش دادهاند همه طیف از جامعه را دربرنمیگیرد (زندانیان، بیماران، نظامیان و...)

چهارمین محدودیت ما در واقع همان عوامل سومی است که در محدودیت اول ذکر شد یعنی تغذیه، میزان ورزش، اعتیاد و... دیگر عواملی که ارتباط تنگاتنگی با

فشارخون و چاقی دارند را ما در نظر نگرفتیم. بارداری (متغیر RIDEXPRG) هم که روی BMI اثر میگذارد کنترل نشده است.

پنجمین محدودیت ما طرح نمونهگیری پیچیده است: فعلا فقط از وزن استفاده کردهایم و طبقه (SDMVSTRA) و خوشه (SDMVPSU) را در نظر نگرفتهایم، پس در فازهای بعد روشهای ساده درسی ممکن است عدم قطعیت را کمتر از مقدار واقعی نشان دهند. خلاصههای توصیفی این گزارش نیز (جز ستونهای وزندار) بدون وزن هستند و فقط درباره افراد نمونه معتبرند.

ششمین محدودیت ما اندازهگیری است: فشارخون فقط قرائت اول از سه قرائت است BMI ،شاخص غیرمستقیم چربی بدن است، و سن 80 سال و بالاتر به صورت «80» کدگذاری شده است و تفاوتهای درون این گروه قابل تشخیص نیست.