پروژه درس آمار- فاز اول

کوثر خردمند
403100319

پاییز 1405

مقدمه

در این فاز از پروژه که داده های مورد استفاده از پیمایش ملی سلامت و تغذیه دوره ۲۰۲۱ تا ۲۰۲۳ است که توسط مرکز کنترل و پیشگیری بیماریهای آمریکا جمع آوری شده است، هدف بررسی ما شناخت وآماده سازی داده، ارائه آمار توصیفی و نهایی سازی سوال آماری برای بررسی توصیفی شاخص توده بدنی و فشار خون سیستولیک در بزرگسالان ۲۰ سال و بالاتر است. در گزارش فاز اول پروژه ما صرفا داده ها را توصیف میکنیم وارایه نتایجی به صورت استنباطی نخواهیم داشت.

منبع داده ها و ادغام

(الزام الف)

ما از سه فایل زیر تحت عنوان داده استفاده کردیم:

DEMO_L :اطلاعات جمعیت شناختی

BMX_L :اندازه گیری های بدنی

BPXO_L :اندازه گیری فشار خون

برای اینکه رکوردهای یک نفر را از سه فایل کنار هم بیاوریم و رکوردی کامل بسازیم از متغیر SEQN استفاده کردیم. وچون صرفا به اطلاعات افرادی نیاز داشتیم که در هر سه فایل باشند نوع ادغام از نوع inner join است.

تعداد رکوردهای اولیه برای DEMO, BMX, BPXOبه ترتیب 11933، 8860 و 7801 بود که پس از ادغام به تعداد 7801 رسید زیرا درواقع به تعداد کوچکترین رکورد مشترک داریم.

نقش وزنهای نمونهگیری

(الزام الف2)

درواقع همانطور که در سورس درس هم گفته شد هدف این است که ما با انتخاب یک جامعه آماری مناسب نتایجمان را تا حد ممکن به کل جامعه تعمیم دهیم.
به دلیل جمعیت بالای آمریکا و پراکندگی زیاد ان روشی که برای نمونهگیری استفاده شده است نمونهگیری چندمرحلهای است اما نکتهای که وجود دارد این است که NHANES با احتمال بیشتری اقلیتها را در نظر میگیرد یعنی سهم انها از سهم واقعی انها در جامعه بیشتر است و دلیل این کار این است که میخواهد داده کافی برای تحلیل سلامتشان داشته باشد و این یعنی هر فرد نماینده تعداد متفاوتی از افراد جامعه است. و از سوی دیگر بعضی از افرادی که انتخاب شدهاند همکاری نمیکنند و راهحلی که برای این موضوع استفاده شده است این است که به افراد دیگری که همکاری کردهاند وزن بیشتری تعلق گیرد تا جای خالی انان پر شود.
پس در نتیجه هر فرد با احتمال برابر انتخاب نمیشود و برای اینکه براوردهای ما از میانگین سوگیری خاصی نداشته باشد از وزن مخصوص بخش معاینه WTMEC2YRاستفاده کردیم تا وزنها را اعمال کنیم.(وزن دیگر، وزن WTINT2YRاست که وزن مخصوص پرسشنامه است نه معاینه)

تعریف جمعیت تحلیلی

(الزام الف 4)

در این بخش ما تعدادی از افراد را به دلایلی که جلوتر خواهیم گفت حذف کردیم. نکته مهمی که وجود دارد این است که با حذف این افراد ایا نتایج ما دچار سوگیری شدهاند یا خیر. ما سه مرتبه فرایند حذف را انجام دادیم مرحله اول فیلتر سن را اعمال کردیم و افرادی که سنشان زیر 20 سال بود را حذف کردیم(این مورد مشکلی به وجود نمی آورد چون سوال ما درمورد افراد بالای 20 سال است) و به این ترتیب 1737 نفر حذف شدند.

فیلتر دوم و سومی که اعمال کردیم حذف افرادی بود که دادهای درمورد BMIو فشارخون انان نداشتیم که خب واضحا مجبور بودیم چون برای جلوگیری از خطا باید مقدار دلخواه میگذاشتیم که منجر به مشکلات دیگری میشد و در نهایت 259 نفر حذف شدند و از تعداد اولیه 7801 به 5805 نفر رسیدیم. در فیلتر دوم و سوم پاسخ ما به سوالی که ابتدا مطرح کردیم این است که بله ممکن است حذف 259 نفر سوگیری ایجاد کند درواقع اگر اینطور به قضیه نگاه کنیم که این افراد چرا نتوانستهاند در همه ازمایشات شرکت کنند و یک دلیل و ویژگی مشخص پیدا کنیم که مانع شده باشد پس ما از یک فاکتور مهم(همان مانع) درحال صرف نظر کردن هستیم! پس باید این موضوع بررسی شود.

آمار توصیفی

(این بخش را در بخش Analysis.java با استفاده از کتابخانه DescriptiveStat istics محاسبه کردیم)

آمار توصیفی شاخص توده بدنی BMI

شاخص	مقدار (kg/m^2)
میانگین	29.73
میانه	28.40
انحراف معیار	7.15
چارک اول Q1	24.70
چارک سوم Q3	33.50
حداقل	11.10
حداکثر	68.90

میانگین 29.73 است و طبق استانداردهای سازمان جهانی بهداشت بالای 30 به معنای چاقی است پس میانگین لبه چاقی است اما باتوجه به میانه(28.4) نصف جمعیت کمتر از ان و نصف جمعیت بیشتر از 28.4 هستند اما تنوع و پراکندگی در جمعیت بالاست(7.15) و باتوجه با اینکه میانگین از میانه بزرگتر است یعنی نمودار right-skewed است که البته در نمودار جلوتر نیز خواهیم دید و این یعنی تعداد کمی از افراد را با چاقی شدید داریم و چون میانه به این مقادیر شدید حساس نیست مقدارش کمتر از میانگین میماند.

آمار توصیفی فشار خون سیستولیک

شاخص	مقدار mmHg
میانگین	123.02
میانه	121.00
انحراف معیار	18.47
حداقل	75.00
حداکثر	225.00

میانگین 123.02 میلیمتر جیوه است و انجمن قلب آمریکا 120 تا 129 را بالا در نظر میگیرد پس میانگین جامعه ما در محدودهی بالا قرار دارد. چون میانه اختلاف کمی با میانگین دارد پس توزیع فشارخون تقریبا متقارن و شبیه به نرمال است. انحراف معیار عدد کوچکی نیست و یعنی پراکندگی قابل توجهای داریم. و البته مقادیر حداقل و حداکثر در فاصله نسبتا زیادی از هم قرار دارند که یعنی بازه وسیعی از فشارخون را داریم.

جدول فراوانی جنس

جنس	فراوانی	درصد
مرد	2619	%45.12
زن	3186	%54.88
مجموع	5805	%100

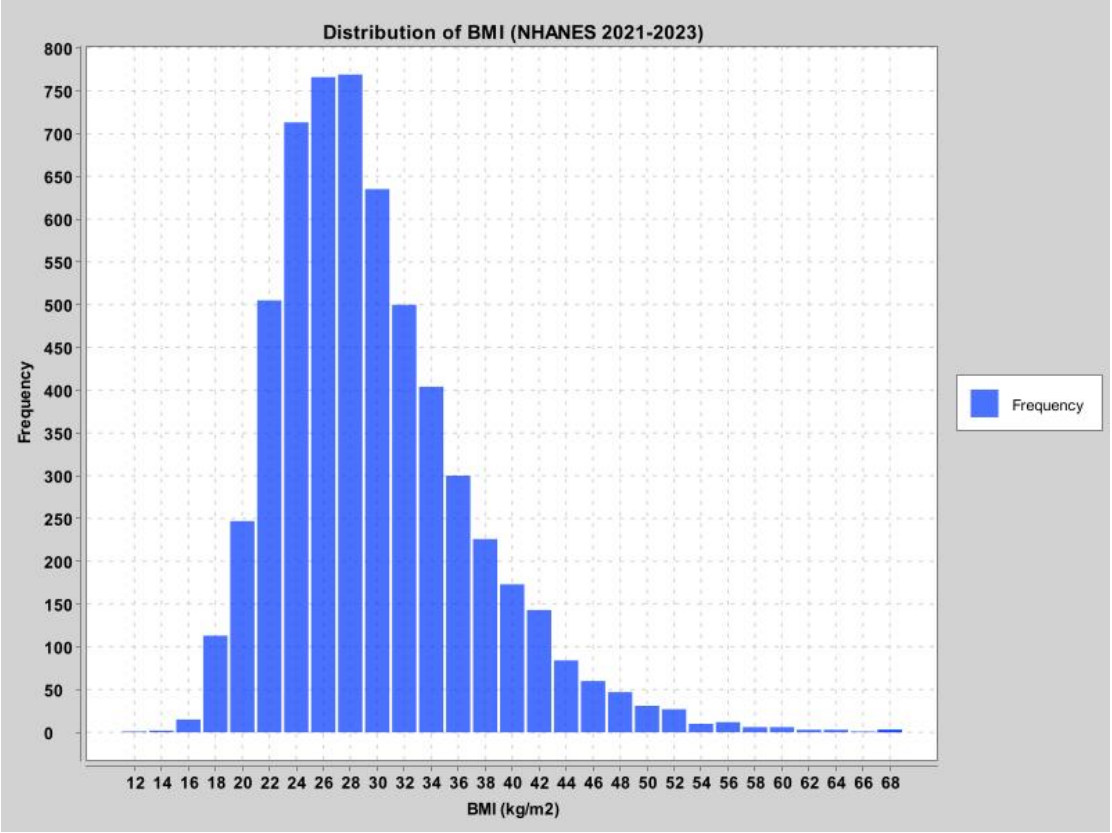
مقایسه برآورد خام و وزندار

(الزام الف 3)

شاخص	برآورد خام	برآورد وزندار	تفاوت
میانگین BMI	29.73	29.60	0.13
میانگین فشارخون	123.02	121.22	1.80
شیوع چاقی (BMI>30)	%40.91	%40.12	%0.79

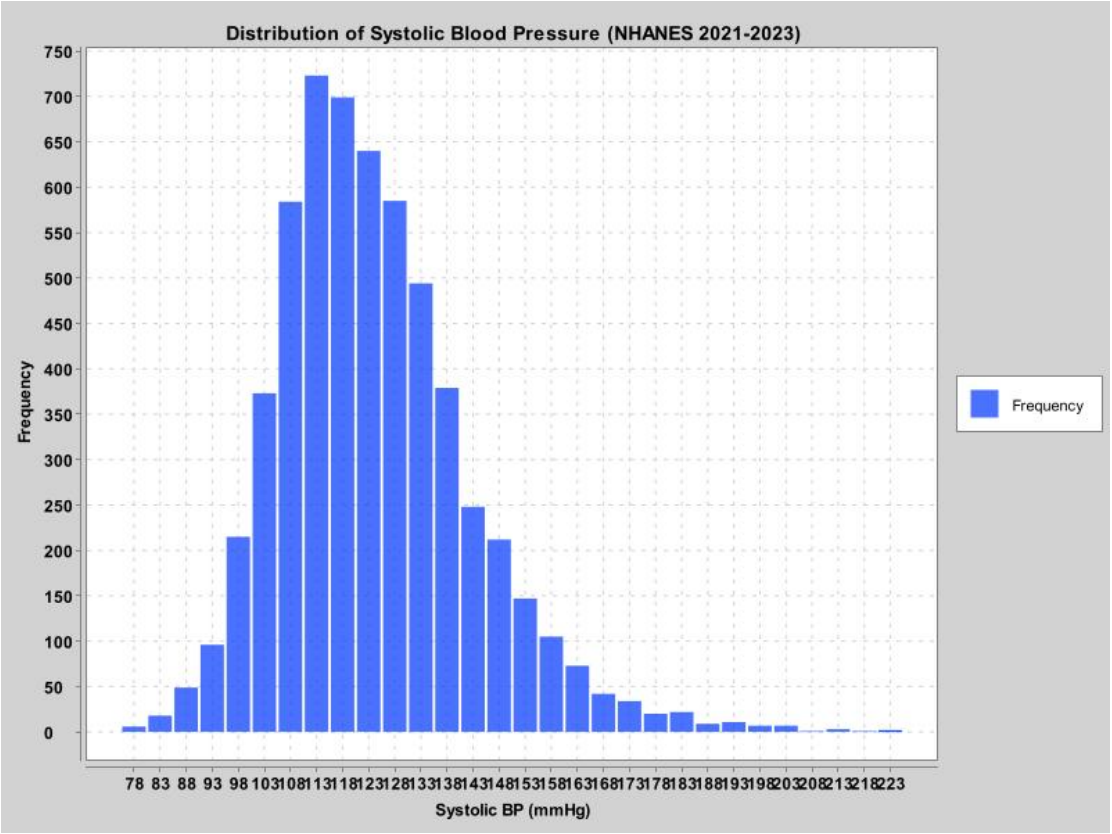
تفاوت بین دو برآورد برای BMI ناچیز است که این نتیجه ان است که نمونه مورد بررسی نماینده مناسبی از کل است و توزیع ما به توزیع جامعه کل نزدیک است. برای فشارخون این تفاوت بیشتر است و حدود 1.80 است که یعنی اگر اثر وزن را درنظر نمیگرفتیم برآوردمان از فشارخون جامعه 1.80 بیشتر از واقعیت میشد و درواقع دلیل این اختلاف هم این است که همانطور که بالاتر گفته شد چون افراد مسن نیز جز اقلیتها در نظر گرفته شدهاند با احتمال بیشتری انتخاب شدند و چون این گروه از افراد اغلب فشارخون بالایی دارند میانگین خام را بالا کشیدهاند و وقتی ما وزن را هم درنظر گرفتیم این عدد کمتر شد و به واقعیت نزدیکتر شدیم.

نمودار ها



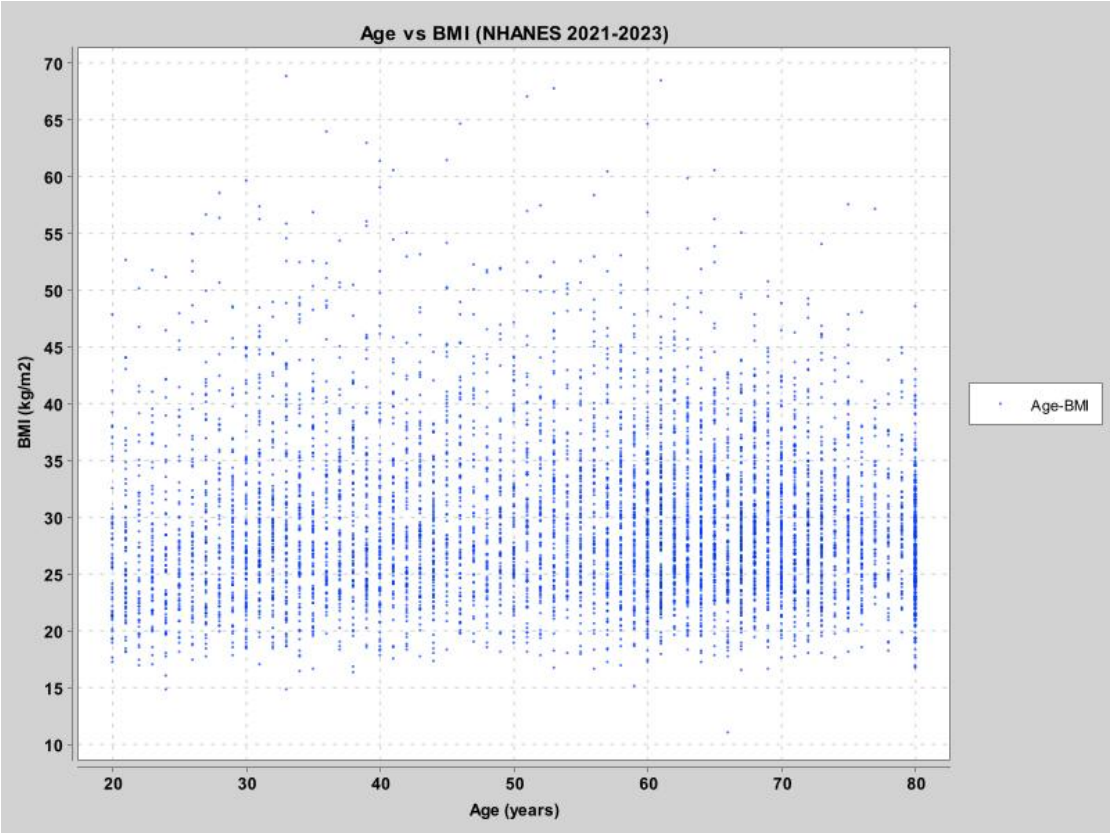
هیستوگرام BMI

این نمودار توزیع شاخص توده بدنی را نشان میدهد. طبق نمودار اکثر افراد BMIبین 25 تا 30 دارند اما دنباله توزیع به سمت مقادیر بزرگتر تا 68 نیز کشیده شده و یعنی تعداد کمی میانگین را بالا میکشند و یعنی میانگین بزرگتر از میانه است و همینطور که مشاهده میشود راست چوله است و توزیع نرمال نیست.



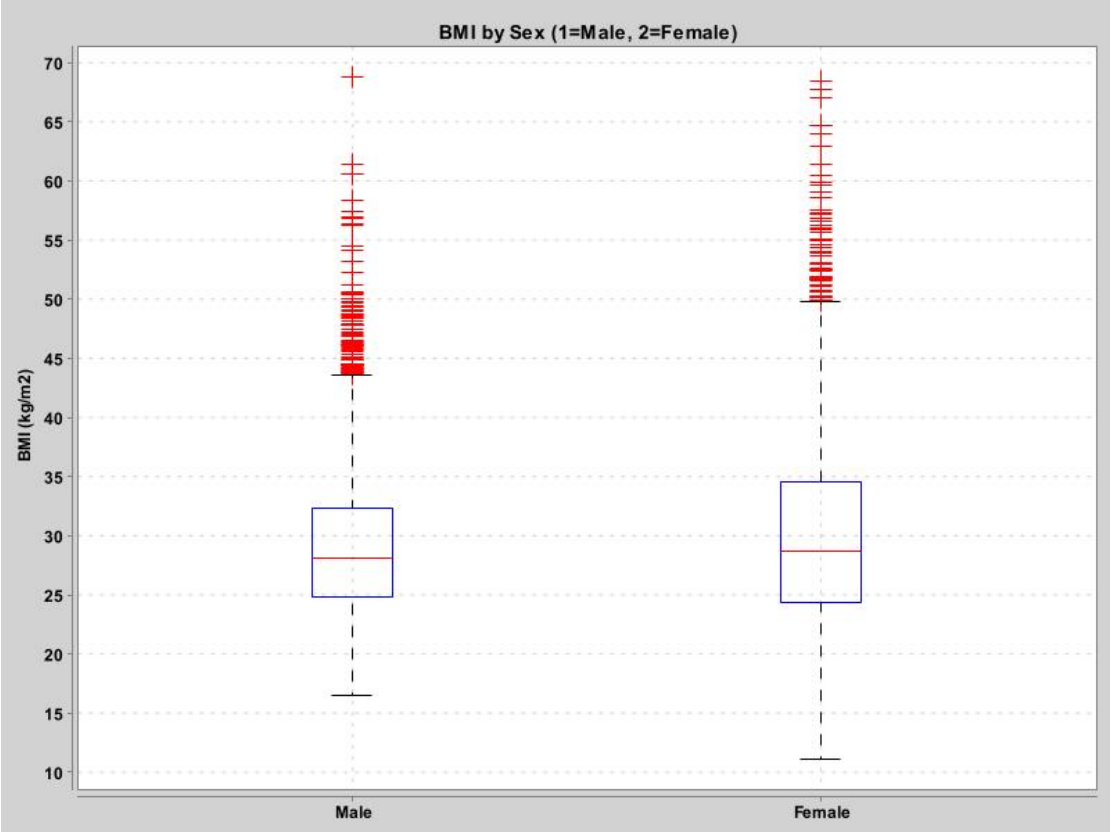
هیستوگرام فشارخون سیستولیک

این نمودار نسبت به قبلی به نرمال بودن نزدیکتر است اما باز هم راست چوله است به دلیل همان افراد با فشارخون بالا اما باز هم به دلیل اینکه فراوانی از 138 به بعد کاهشی است یک تقارن نسبی داریم. درواقع شاید بتوان اینگونه تحلیل کرد که چرا فشارخون برخلاف BMIتقریبا نرمال است زیرا فشارخون تحت تاثیر عوامل فیزیولوژیکی زیادی هست که هرکدام اثر کوچکی دارند و طبق قضیه حد مرکزی مجموع این اثرات کوچک به توزیع نرمال منجر میشود اما درمورد BMI اغلب با سبک زندگی گره خورده و مشابه حالت فشارخون نیست.



رابطه بین سن و شاخص توده بدنی

در نمودار بالا هر نقطه نماینده یک BMI یک فرد با سن مشخص است. در این نمودار رابطه خطیای واضحا دیده نمیشود. از سن 20 تا حدود50
تعداد افراد با BMI بالا بیشتر از بازه 50 به بعد است یعنی پراکندگی مقادیر بسیار بالا کاهش میابد دلیلی که شاید بتواند این تغییر را توجیه کند این است که چون با افزایش سن هم مواجه هستیم پس احتمالا افرادی که در سنین پایین دچار چاقی شدید بودند به بیمارهایی نظیر بیماری قلبی مبتلا شدهاند و در نتیجه زودتر فوت کردهاند و درکل شانس کمتری برای عمر طولانی دارند.



مقایسه توزیعBMI بین مردان و زنان

خط وسط هر جعبه میانه است که تقریبا برای هردو جنس برابر با 28 است .

برای مردان بالای حدود 43 و برای زنان بالای حدود 50 هر چه هست پرت محسوب میشود. وجود تعداد زیاد پرت در بالا و بلندتر بودن سبیل بالایی نسبت به پایینی نشان میدهد توزیع BMI در هر دو گروه راست چوله است. همچنین جعبه زنان بلندتر است (حدود 24 تا 35 در مقابل 25 تا 32برای مردان)، یعنی پراکندگی BMI در زنان بیشتر است. چون میانه در هردو یکسان است نمیتوان صرفا برحسب این نمودار تعیین کرد که زنان چاقترند یا مردان صرفا میتوانیم بگوییم که چون خط 30 داخل جعبه هر دو قرار دارد و Q3 زنان بالاتر است، پس احتمالاً سهم زنان با BMI بالای 30 بیشتر است.

سوال آماری

‘‘آیا میانگین شاخص توده بدنیBMI در بزرگسالان بیست سال و بالاتر، بین گروههای سنی و جنسی مختلف تفاوت معناداری دارد؟ و آیا این تفاوتها پس از در نظر گرفتن وزنهای نمونهگیریNHANES پایدار میمانند؟’’

چرا این سوال برای دادههای ما مناسب است؟

در سوال مطرح شده متغیرهای BMI، سن و جنس وجود دارند و همچنین به وزن نمونه هم اشاره شده و دادههای NHANES نیز دقیقا این متغیرها را دارد. دلیل بعدی هم تعداد کافی داده ها است که به قدری هست که بتوان میانگین گروههایی که افراز کردیم را دقیق برآورد کنیم. همچنین، نمودارهای فاز1 نشان دادند که توزیع BMIدر مردان و زنان تفاوتهایی در پراکندگی دارد و درسنین بالای 60 سال دنبالهی چاقی شدید کوتاهتر میشود. این شواهد توصیفی، سؤال ما را کاملاً با داده هماهنگ میکند.

محدودیتها

اولین محدودیت ما مشاهدهای بودن دادهها است یعنی ما صرفا میتوانیم همبستگی را نشان دهیم و نه علیت را در واقع مانند همان مثال مطرح شده در کارگاه که مصرف شیر و دریافت جایزه نوبل درحالی که عامل سوم رفاه است که نادیده گرفته میشود اینجا هم نمیتوانیم بگوییم اگر افراد چاق فشارخون بالا دارند پس چاقی عامل فشارخون بالاست(مثلا تغذیه نامناسب است که باعث هردو اینها میشود).

دومین محدودیت ما همان دویست و پنجاه نفری بود که حذف کردیم درواقع اینها که داده گمشده نامیده میشوند همانطور که گفتیم میتواند منجر به سوگیری خاصی در برآورد ما شوند.

سومین محدودیت ما این است که دادهها برای یک مقطع زمانی دو ساله هستند یعنی نمیتوانیم تغییرات در طول زمان را ببینیم بخصوص اینکه بنظرم چون بازه زمانی با شیوع کرونا همپوشانی دارد و ان بازه زمانی شرایط خاص محسوب میشود شاید داشتن داده در بازههای زمانی دیگر نیز به دقیق کردن برآورد کمک میکرد. البته اینکه حتی مجموعه افرادی که آزمایش دادهاند همه طیف از جامعه را دربرنمیگیرد(زندانیان،بیماران،نظامیان و...)

چهارمین محدودیت ما درواقع همان عوامل سومی است که در محدودیت اول ذکر شد یعنی تغذیه، میزان ورزش، اعتیاد و... دیگر عواملی که ارتباط تنگاتنگی با فشارخون و چاقی دارند را ما درنظر نگرفتیم.