پروژه درس آمار- فاز اول

کوثر خردمند

403100319

پاییز1405

مقدمه

در این فاز از پروژه که دادههای مورد استفاده از پیمایش ملی سلامت و تغذیه دوره 2021 تا 2023 است که توسط مرکز کنترل و پیشگیری بیماریهای آمریکا جمعآوری شده است، هدف برای ما شناخت و آمادهسازی داده، ارائه آمار توصیفی و نهاییسازی سؤال آماری برای بررسی توصیفی شاخص توده بدنی و فشار خون سیستولیک در بزرگسالان 20 سال و بالاتر است. در گزارش فاز اول پروژه ما صرفا دادهها را توصیف میکنیم و ارائه نتایجی به صورت استنباطی نخواهیم داشت.

منبع داده ها و ادغام

(الزام الف)

ما از سه فایل زیر تحت عنوان داده استفاده کردیم:

DEMO_L: اطلاعات جمعیت شناختی

BMX_L: اندازه گیری های بدنی

BPXO_L: اندازه گیری فشار خون

برای اینکه رکوردهای یک نفر را از سه فایل کنار هم بیاوریم و رکوردی کامل بسازیم از متغیر SEQN استفاده کردیم. وچون صرفا به اطلاعات افرادی نیاز داشتیم که در هر سه فایل باشند نوع ادغام از نوع inner join است.

تعداد رکوردهای اولیه برای DEMO, BMX, BPXO به ترتیب 8860 ،11933 و 7801بود که پس از ادغام به تعداد 7801 رسید زیرا در واقع به تعداد کوچکترین رکورد مشترک داریم. در هیچکدام از سه فایل SEQN تکراری وجود نداشت و هر فرد موجود در BMX_L و BPXO_L در DEMO_L نیز حضور داشت.

فایل	تعداد رکورد	افراد یکتا(SEQN)
DEMO_L	11933	11933
BMX_L	8860	8860
BPXO_L	7801	7801
مشترک بین هر سه فایل	7801	7801

نقش وزنهای نمونهگیری

(الزام الف2)

در واقع همانطور که در درس هم گفته شد هدف این است که ما با انتخاب یک جامعه آماری مناسب نتایجمان را تا حد ممکن به کل جامعه تعمیم دهیم. به دلیل جمعیت بالای آمریکا و پراکندگی زیاد آن روشی که برای نمونهگیری استفاده شده است نمونهگیری چندمرحلهای است اما نکتهای که وجود دارد این است که NHANESبا احتمال بیشتری اقلیتها را در نظر میگیرد یعنی سهم آنها از سهم واقعی آنها در جامعه بیشتر است و دلیل این کار این است که میخواهد داده کافی برای تحلیل سلامتشان داشته باشد و این یعنی هر فرد نماینده تعداد متفاوتی از افراد جامعه است. و از سوی دیگر بعضی از افرادی که انتخاب شدهاند همکاری نمیکنند و راهحلی که برای این موضوع استفاده شده است این است که به افراد دیگری که همکاری کردهاند وزن بیشتری تعلق گیرد تا جای خالی آنان پر شود. پس در نتیجه هر فرد با احتمال برابر انتخاب نمیشود و برای اینکه برآوردهای ما از میانگین سوگیری خاصی نداشته باشد از وزن مخصوص بخش معاینه WTMEC2YRاستفاده کردیم تا وزنها را اعمال کنیم. (وزن دیگر WTINT2YR ، است که وزن مخصوص پرسشنامه است نه معاینه)

تعریف جمعیت تحلیلی

(الزام الف4)

در این بخش جمعیت تحلیلی را گامبهگام تعریف میکنیم. معیارهای ورود به تحلیل اینها هستند: سن 20 سال و بالاتر، و وجود همزمان ،BMI فشارخون سیستولیک (BPXOSY1)و وزن معاینه .(WTMEC2YR) حذف افراد زیر 20 سال مشکلی برای تفسیر ایجاد نمیکند، چون جمعیت مورد نظر ما بزرگسالان هستند. جدول زیر تعداد افراد باقیمانده و حذفشده را بعد از هر مرحله نشان میدهد.

مرحله	معیار	باقیمانده	حذفشده
0	همه شرکتکنندگانDEMO_L	11933	—
1	سن 20 سال و بالاتر	7809	4124
2	BMIموجود	5970	1839
3	فشارخون سیستولیک موجود	5805	165
4	وزن معاینه موجود و مثبت	5805	0

از 1839 نفر حذفشده در مرحله ،2 تعداد 1745 نفر در BMX_L حضور ندارند و 94نفر رکورد دارند ولی BMI برایشان ثبت نشده است. تعداد بزرگسالان غایب در BPXO_L هم 1745 نفر است که به احتمال زیاد همان افرادی هستند که در بخش معاینه شرکت نکردهاند (این موضوع با متغیر RIDSTATR بررسی نشده است). در مرحله ،3 هر 165 نفر حذفشده در BPXO_L حضور دارند ولی فشارخون سیستولیک آنها ثبت نشده است. در مرحله 4 کسی حذف نشد چون همه افراد باقیمانده وزن معاینه مثبت دارند. نمونه نهایی 5805 نفر است.

ممیزی کیفیت داده

(تسک مشترک5)

پیش از تحلیل، کیفیت داده را با برنامه Audit.java بررسی کردیم. نتیجه هر بررسی و تصمیم ما در جدول زیر آمده است.

بررسی	نتیجه	تصمیم و دلیل
SEQNتکراری	0در هر سه فایل	نیاز به اقدام نیست
سلول متنی غیرعددی در ستونهای اصلی	0	نیاز به اقدام نیست
سن، جنس و وزن گمشده (بزرگسالان)	0	نیاز به اقدام نیست
BMIگمشده	1839نفر (23.55% بزرگسالان)	حذف (تحلیل موارد کامل)؛ جایگذاری با مقدار دلخواه سوگیری ایجاد میکند
فشارخون سیستولیک گمشده	1946نفر (24.92% بزرگسالان)	حذف، به همین دلیل
BMIخارج از بازه 10 تا80	0	اقدامی لازم نیست (دامنه مشاهدهشده 11.1 تا(68.9
فشارخون خارج از بازه 60 تا 260	0	اقدامی لازم نیست (دامنه مشاهدهشده 75 تا 225)
وزن غیرمثبت، جنس غیر از 1 و ،2 کد ویژه 777 یا بیشتر	0	اقدامی لازم نیست
سن ثبتشده) «80» کدگذاری سقفی)	308نفر(5.31%)	نگه داشته شد؛ در تفسیر، تفاوت سنین بالای 80 قابل تشخیص نیست

بازههای 10 تا 80 برای BMI و 60 تا 260 برای فشارخون مقادیر محتملی هستند که خودمان برای ممیزی تعریف کردیم و حدود رسمی NHANES نیستند.

بررسی سوگیری ناشی از حذف افراد فاقد فشارخون

(الزام الف4)

در مرحله 3 ،165 بزرگسال که BMI و وزن معاینه دارند فقط به این دلیل حذف شدند که فشارخون سیستولیک نداشتند. جدول زیر این گروه را با نمونه اصلی مقایسه میکند.

ویژگی	نمونه اصلی	حذفشدگان (فاقد فشارخون)
تعداد	5805	165
میانگین سن	53.9	51.8
میانه سن	57	51
درصد زنان	54.9	63.0
درصد 60 ساله و بالاتر	45.7	40.6
میانگینBMI	29.73	33.24
میانهBMI	28.40	29.60

گروه حذفشده حدود 2.8 درصد از 5970 بزرگسال دارای BMI است. میانگین BMIدر آنها حدود 3.5 واحد بیشتر است، اما اختلاف میانه فقط 1.2 است؛ یعنی بخشی از اختلاف میانگین از چند مقدار بسیار بزرگ میآید. با 165 نفر این مقایسه فقط توصیفی است. اینکه چرا فشارخون این افراد ثبت نشده در داده بررسی نشده و هر توضیحی فقط یک فرضیه است. وزنهای نمونهگیری این حذف را جبران نمیکنند. اثر آن در فاز پنجم با تحلیل حساسیت (تکرار تحلیل روی نمونهای که فقط BMIرا لازم دارد) بررسی خواهد شد.

آمار توصیفی

)این بخش را در Analysis.java با استفاده از کتابخانه DescriptiveStatistics محاسبه کردیم(

آمار توصیفی شاخص توده بدنیBMI

شاخص	مقدار(kg/m^2)
میانگین	29.73
میانه	28.40
انحراف معیار	7.15
چارک اولQ1	24.70
چارک سومQ3	33.50
حداقل	11.10
حداکثر	68.90

میانگین 29.73 است و طبق استانداردهای سازمان جهانی بهداشت بالای 30 به معنای چاقی است پس میانگین لبه چاقی است. اما با توجه به میانه (28.4) نصف جمعیت کمتر از آن و نصف جمعیت بیشتر از 28.4 هستند اما تنوع و پراکندگی در جمعیت بالاست (7.15) و با توجه با اینکه میانگین از میانه بزرگتر است یعنی نمودار right-skewed است که البته در نمودار جلوتر نیز خواهیم دید. یعنی تعداد کمی از افراد را با چاقی شدید داریم و چون میانه به این مقادیر شدید حساس نیست مقدارش کمتر از میانگین میماند.

آمار توصیفی فشار خون سیستولیک

شاخص	مقدارmmHg
میانگین	123.02
میانه	121.00
انحراف معیار	18.47
حداقل	75.00
حداکثر	225.00
چارک اول Q1	110.00
چارک سوم Q3	133.00

میانگین 123.02 میلیمتر جیوه است و انجمن قلب آمریکا 120 تا 129 را بالا در نظر میگیرد پس میانگین جامعه ما در محدودهی بالا قرار دارد. چون میانه اختلاف کمی با میانگین دارد پس توزیع فشارخون تقریبا متقارن و شبیه به نرمال است. انحراف معیار عدد کوچکی نیست و یعنی پراکندگی قابل توجهی داریم. البته مقادیر حداقل و حداکثر در فاصله نسبتا زیادی از هم قرار دارند که یعنی بازه واقعی از فشارخون را داریم.

جدول BMI برحسب گروه سنی

گروه سنی	تعداد	BMIمیانگین	انحراف معیار
39-20 سال	1482	29.34	7.81
59-40 سال	1668	30.48	7.59
60 سال به بالا	2655	29.48	6.40

جدول فراوانی جنس

جنس	تعداد	درصد فراوانی
مرد	2619	%45.12
زن	3186	%54.88
مجموع	5805	%100

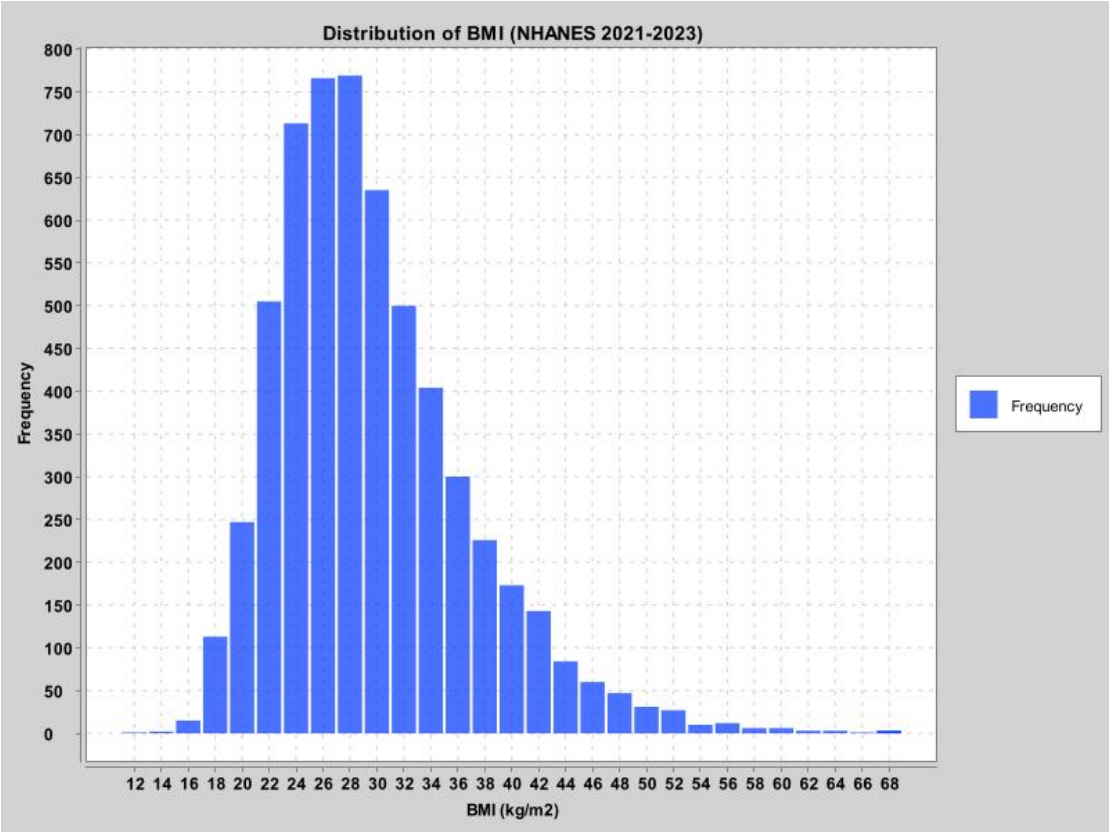
مقایسه برآورد خام و وزندار

(الزام الف3)

شاخص	برآورد خام	برآورد وزندار	تفاوت
میانگینBMI	29.73	29.60	0.13
میانگین فشارخون	123.02	121.22	1.80
شیوع چاقی(BMI ≥ 30)	%40.91	%40.12	%0.79
میانگین سن	53.85	48.88	4.97

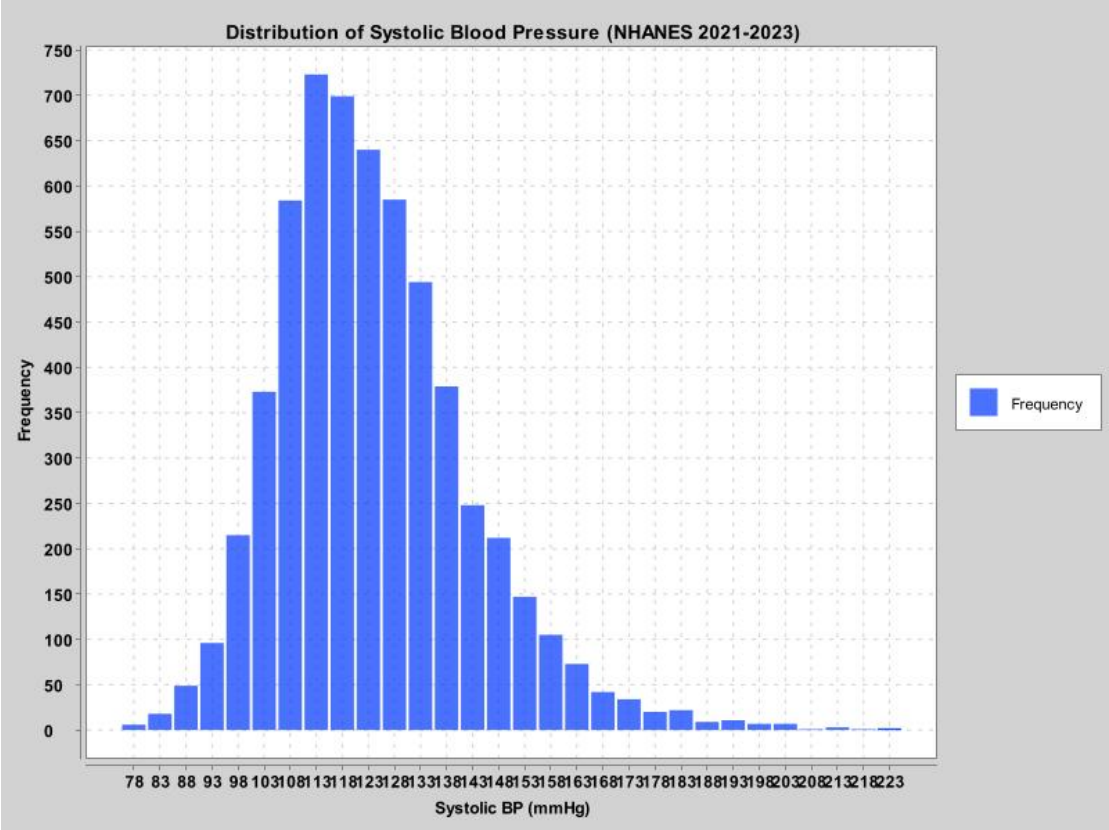
تفاوت بین دو برآورد برای BMI ناچیز است که این نتیجه آن است که نمونه مورد بررسی نماینده مناسبی از کل است و توزیع ما به توزیع جامعه کل نزدیک است. برای فشارخون این تفاوت بیشتر است و حدود 1.80 است که یعنی اگر اثر وزن را در نظر نمیگرفتیم برآوردمان از فشارخون جامعه 1.80 بیشتر از واقعیت میشد و در واقع دلیل این اختلاف هم این است که همانطور که بالاتر گفته شد چون افرادی که جزو اقلیتها در نظر گرفته شدهاند با احتمال بیشتری انتخاب شدند و چون این گروه از افراد اغلب فشارخون بالایی دارند(یک گروه از اقلیتها سالمندان هستند که با توجه به میانگین سن مشخص است که بیشتر از سهم واقعیشان بودند) میانگین خام را بالا کشیدهاند وقتی ما وزن را هم در نظر گرفتیم این عدد کمتر شد و به واقعیت نزدیکتر شدیم.

نمودار ها



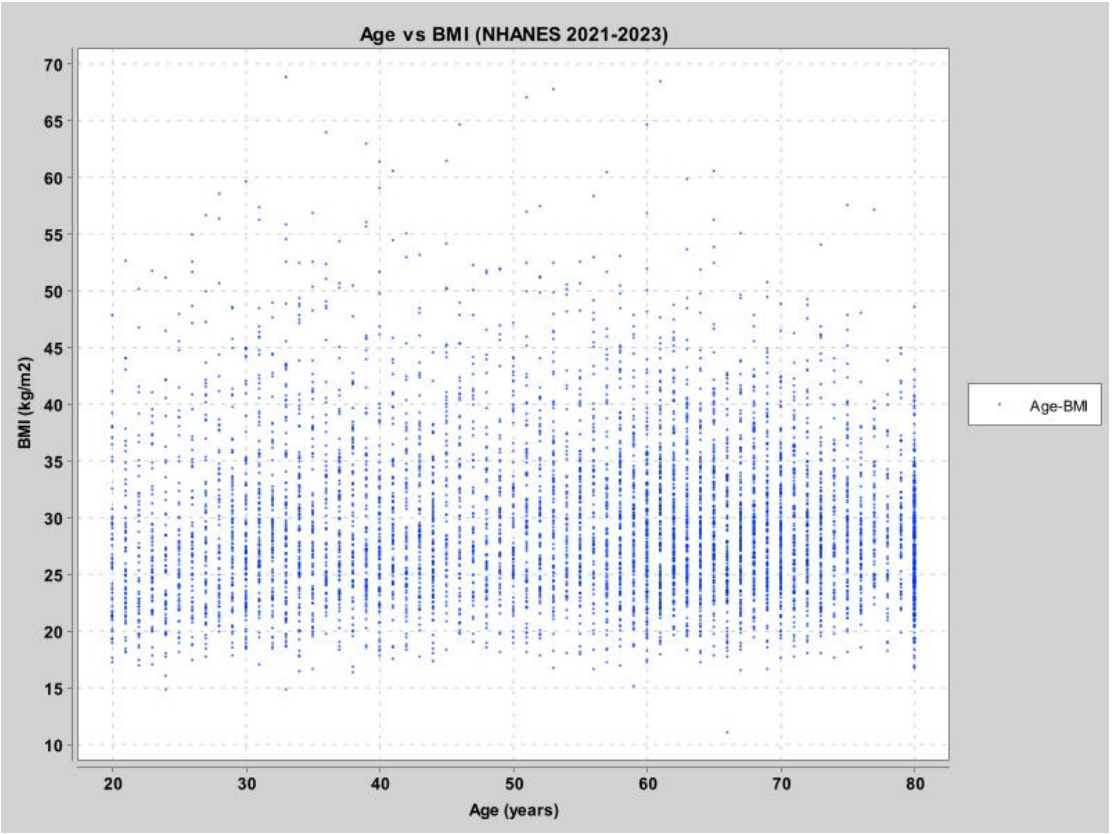
هیستوگرامBMI

این نمودار توزیع شاخص توده بدنی را نشان میدهد. طبق نمودار اکثر افراد BMI بین 25 تا 30 دارند اما دنباله توزیع به سمت مقادیر بزرگتر تا 68 نیز کشیده شده و یعنی تعداد کمی میانگین را بالا میکشند و یعنی میانگین بزرگتر از میانه است و همینطور که مشاهده میشود راست چوله است و توزیع نرمال نیست.



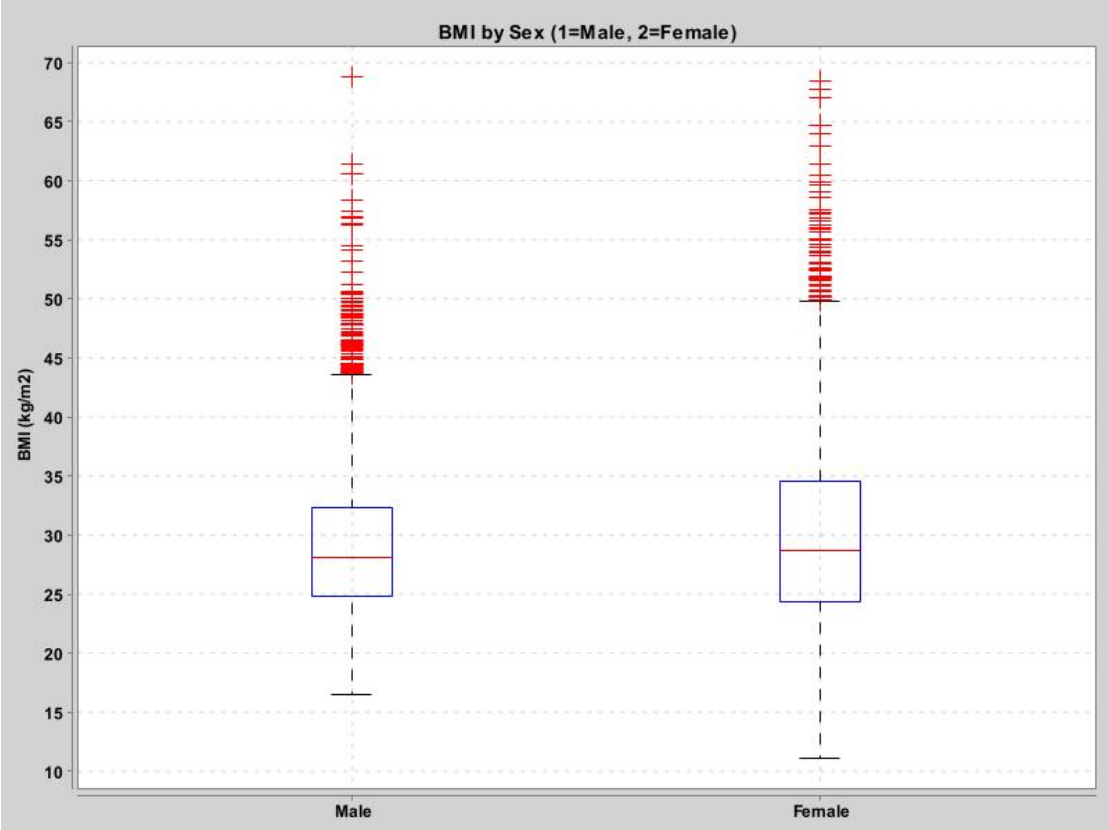
هیستوگرام فشارخون سیستولیک

این نمودار نسبت به قبلی به نرمال بودن نزدیکتر است اما باز هم راست چوله است به دلیل همان افراد با فشارخون بالا اما باز هم به دلیل اینکه فراوانی از 138 به بعد کاهشی است یک تقارن نسبی داریم. در واقع شاید بتوان اینگونه تحلیل کرد که چرا فشارخون برخلاف BMI تقریبا نرمال است زیرا فشارخون تحت تاثیر عوامل فیزیولوژیکی زیادی هست که هرکدام اثر کوچکی دارند و طبق قضیه حد مرکزی مجموع این اثرات کوچک به توزیع نرمال منجر میشود اما در مورد BMIاغلب با سبک زندگی گره خورده و مشابه حالت فشارخون نیست.



رابطه بین سن و شاخص توده بدنی

در نمودار بالا هر نقطه نماینده یک BMI یک فرد با سن مشخص است. در این نمودار رابطه خطیای واضحا دیده نمیشود. از سن 20 تا حدود 50 تعداد افراد با BMIبالا بیشتر از بازه 50 به بعد است یعنی پراکندگی مقادیر بسیار بالا کاهش میبابد دلیلی که شاید بتواند این تغییر را توجیه کند این است که چون با افزایش سن هم مواجه هستیم پس احتمالا افرادی که در سنین پایین دچار چاقی شدید بودند به بیماریهایی نظیر بیماری قلبی مبتلا شدهاند و در نتیجه زودتر فوت کردهاند و در کل شانس کمتری برای عمر طولانی دارند.



مقایسه توزیع BMI بین مردان و زنان

خط وسط هر جعبه میانه است که تقریبا برای هردو جنس برابر با 28 است. برای مردان بالای حدود 43 و برای زنان بالای حدود 50 هر چه هست پرت محسوب میشود. وجود تعداد زیاد پرت در بالا و بلندتر بودن سبیل بالایی نسبت به پایینی نشان میدهد توزیع BMI در هر دو گروه راست چوله است. همچنین جعبه زنان بلندتر است (حدود 24 تا 35 در مقابل 25 تا 32 برای مردان)، یعنی پراکندگی BMIدر زنان بیشتر است. چون میانه در هردو یکسان است نمیتوان صرفا بر حسب این نمودار تعیین کرد که زنان چاقترند یا مردان صرفا میتوانیم بگوییم که چون خط 30 داخل جعبه هر دو قرار دارد و Q3 زنان بالاتر است، پس احتمالا سهم زنان با BMI بالای 30 بیشتر است.

سؤال آماری

‘‘آیا میانگین BMI در بزرگسالان 20 سال و بالاتر ساکن آمریکا (اوت 2021 تا اوت2023) میان سه گروه سنی 59-40 ، 39-20 ، 60سال و بالاتر و میان دو جنس متفاوت است، و آیا تصویر حاصل با در نظر گرفتن وزنهای نمونهگیری معاینهی NHANES تغییر میکند؟’’

چرا این سؤال برای دادههای ما مناسب است؟

در سؤال مطرح شده متغیرهای ،BMI سن و جنس وجود دارند و همچنین به وزن نمونه هم اشاره شده و دادههای NHANES نیز دقیقا این متغیرها را دارد. دلیل بعدی هم تعداد کافی دادهها است که به قدری هست که بتوان میانگین گروههایی که افراز کردیم را دقیق برآورد کنیم. همچنین، نمودارهای فاز 1 نشان دادند که توزیع BMIدر مردان و زنان تفاوتهایی در پراکندگی دارد و در سنین بالای 60 سال دنبالهی چاقی شدید کوتاهتر میشود. این شواهد توصیفی، سؤال ما را کاملا با داده هماهنگ میکند.

محدودیتها

اولین محدودیت ما مشاهدهای بودن دادهها است یعنی ما صرفا میتوانیم همبستگی را نشان دهیم و نه علیت را؛ در واقع مانند همان مثال مطرح شده در کارگاه که مصرف شیر و دریافت جایزه نوبل در حالی که عامل سوم رفاه است که نادیده گرفته میشود. اینجا هم نمیتوانیم بگوییم اگر افراد چاق فشارخون بالا دارند پس چاقی عامل فشارخون بالاست (مثل تغذیه نامناسب است که باعث هردو اینها میشود).

دومین محدودیت ما دادههای گمشده است. از بزرگسالان 1745 ،نفر در BMX_L حضور نداشتند 94 ،نفر BMI ثبتشده نداشتند و 165 نفر فشارخون سیستولیک ثبتشده نداشتند و حذف شدند. گمشدگی ناشی از شرکت نکردن در معاینه تا حدی با وزن WTMEC2YR تعدیل میشود، اما حذف 165 نفر فاقد فشارخون را وزنها جبران نمیکنند و چون میانگین BMI این گروه حدود 3.5 واحد بالاتر است (جدول بخش قبل) ممکن است سوگیری ایجاد کند. اثر این حذف در فاز پنجم با تحلیل حساسیت بررسی میشود.

سومین محدودیت ما این است که دادهها برای یک مقطع زمانی دو ساله هستند یعنی نمیتوانیم تغییرات در طول زمان را ببینیم بخصوص اینکه بنظرم چون بازه زمانی با شیوع کرونا همپوشانی دارد و آن بازه زمانی شرایط خاص محسوب میشود شاید داشتن داده در بازههای زمانی دیگر نیز به دقیق کردن برآورد کمک میکرد. البته اینکه حتی مجموعه افرادی که آزمایش دادهاند همه طیف از جامعه را دربرنمیگیرد (زندانیان، بیماران، نظامیان و...)

چهارمین محدودیت ما در واقع همان عوامل سومی است که در محدودیت اول ذکر شد یعنی تغذیه، میزان ورزش، اعتیاد و... دیگر عواملی که ارتباط تنگاتنگی با فشارخون و چاقی دارند را ما در نظر نگرفتیم.